

COMET: Un Marco Neural para la Evaluación de MT

Ricardo Rei

Craig Stewart

Ana C Farinha

Alon Lavie

Unbabel AI

Traducción de este texto a español. Contexto: Página 1 del PDF. Texto: Devuelve SOLO el texto traducido, nada más.

Resumen

Presentamos COMET, un marco neuronal para entrenamiento de evaluación de traducción automática multilingüe. Los modelos de evaluación que obtenemos un nuevo estado de la comunidad de investigación en gran medida. Nuestra tarea de trabajo aprovecha los recientes avances en el lenguaje preentrenado multilingüe y la Tarea Compartida recibió un total de 153 sistemas de MT adaptables que exploran información tanto de la entrada de origen como de la traducción de referencia del idioma objetivo en orden para predecir con mayor precisión la calidad de MT. Para mostrar nuestro marco de trabajo, entrenamos tres modelos con diferentes tipos de juicios humanos: Evaluaciones Directas, Transmisión Mediada por Humanos, Tasa de Edición, Calidad Multidimensional y Métricas de N-gramas. Nuestros modelos logran un nuevo estado de la comunidad de última generación en el WMT 2019 Tarea Compartida de rics y demuestra robustez para sistemas de alto rendimiento.

Mientras que un interés de investigación aumentado en métodos para entrenar modelos y sistemas de MT dio lugar a una mejora reciente y dramática en MT, la evaluación de MT se ha quedado atrás. El MT la comunidad de investigación aún depende en gran medida de métricas y no se ha adoptado ningún nuevo estándar ampliamente. En 2019, la Traducción de Noticias WMT La Tarea Compartida recibió un total de 153 sistemas de MT presentados (Barrault et al, 2019). Las Métricas de una Tarea Compartida del mismo año solo vio 24 sub-misiones, casi la mitad de las cuales eran participantes en la Tarea Compartida de Estimación de Calidad, adaptada como Devuelve SOLO el texto traducido, nada más. Los hallazgos de la tarea anteriormente mencionada de a ilumina dos desafíos principales para la evaluación de MT que abordamos aquí (Ma et al. ,2019). En otras palabras, que las métricas actuales correlacionar exactamente con el juicio humano en segundo nivel de manera que no logran diferenciar adecuadamente los sistemas de MT de mayor rendimiento. Por lo tanto, se proporcionó

1 Introducción

Históricamente, las métricas para evaluar la calidad de la traducción automática (MT) ha confiado en la evaluación de MT adaptables que pueden funcionar como métricas. Nuestro marco de trabajo se beneficia de los recientes avances en el lenguaje interlingüístico y una traducción de referencia generada por humanos en el idioma objetivo. Las métricas tradicionales se han centrado en características básicas a nivel léxico, como el número de n-gramas coincidentes entre la MT y otros (2019) para generar estimaciones de predicción de hipótesis y la traducción de referencia. Métricas de juicio de hombre como Evaluaciones Directas (D) como B LEU (Dienstra, 2012) y el texto traducido (D) (Damen et al, 2019) Transmisión Mediada por Humanos (D) (Dev et al, 2019) y la Tasa de Edición (ETER) (Snover et al, 2006) y un medio para evaluar los sistemas de MT debido a métricas compatibles con Calidad Multidimensional (Métrica de la Comunidad) (el et al, 2014).

Los enfoques neuronales modernos para la traducción automática reciente en Estimación de Calidad (GE) que demostró que es posible lograr mayor calidad de traducción que a menudo se da por sentado. altos niveles de correlación con los juicios humanos de la transferencia léxica monótona entre idiomas. Incluso sin una traducción de referencia (Fensholt et al. 2019), proponemos un enfoque novedoso para incorporar para proporcionar una estimación precisa de la calidad de MT (Barrault et al, 2019).

¹Crosslingual. Optimizado métrica para la evaluación de TTraducción. Devuelve SOLO el texto traducido, nada más.

traduciendo la entrada del idioma fuente en nuestros modelos de MT para construir tokens enmascarados al descubrir los patrones de sustitución. Tradicionalmente solo los modelos de ELMo capturan la relación entre esos tokens y el contexto de la entrada de la fuente, mientras que las evaluaciones QNMT se entrenan con datos de entrenamiento donde las métricas de evaluación dependen en cambio de la traducción objetivo preferida. Como TokenHashi et al (2020), mostramos que este enfoque ha encontrado que es altamente efectivo en interlingüística para utilizar un espacio de incrustación multilingüe no supervisado como la clasificación de documentos y naturalmente para aprovechar la información de las tres entradas de lenguaje. Gouheau et al (2019), generalizando bien a idiomas y guiones no latinos (y otros (2019)). Para los experimentos en este documento,

2 Arquitecturas de Modelos

Los juicios humanos sobre la calidad de la MT generalmente llegan en la forma de puntuaciones a nivel de segmento como DA, Contexto: Página 2 del PDF ■■ Texto a traducir: MOM y HTER. Para DA, es una práctica común Devuelve convertir puntuaciones en clasificación (Resnet) el número de anotaciones por segmento es limitado el trabajo puede capturar información lingüística que es relevante para diferentes tareas posteriores. En el caso de la evaluación de Ling et al(2020) mostró que las diferentes capas pueden alcanzar diferentes niveles de relación y que utilizando solo la última capa a menudo resulta en un rendimiento inferior. En este trabajo, nosotros utilizó el enfoque descrito en Peters et al(■■■) De devuelve SOLO y recopilar información de los más importantes encapas de codificador en una única incrustación para cada u Kené, utilizando un mecanismo de atención por capas. Este incrustado se calcula entonces como:

e_{xj}




Traduce el siguiente texto español al inglés

x_j

2.1 Codificador Translingüístico

El bloque de construcción primario de todos los modelos correspondiente a los pesos entrenables capa por capa. En nuestro marco de trabajo es un preentrenado, predefinido, no sobreajuste a la información contenida en cualquier capa única, utilizamos el abandono de modelo como BERT multilingüe (Devlin et al., 2019), XLM (Conneau y Lample, 2019) o XLM-RoBERTa (Conneau et al, 2019). Estos modelos Tied weights (Senkova, 2018) español y Contexto: Página 2 de 10. Probabilidad del peso α Type de configuración de los parámetros de int. contienen varias capas de codificador transformado. Fuente: Reimers y Gurevych (2019).

²En la Tarea Compartida de Métricas WMT, si la diferencia entre las puntuaciones DA no es mayor de 25 puntos, esos segmentos están excluidos de los datos RR.

Figura 2: Arquitectura del modelo de clasificación de traducción. El sistema recibe 4 segmentos: la fuente, el referente, una hipótesis "mejor" y una "peor". Estos segmentos se modifican de forma independiente utilizando un codificador entrenado en varios idiomas y una capa de agrupación de contexto. Página 3 del PDF  Texto  **Sahar**  **afual**: arriba. Finalmente (2015) optimizamos el espacio de incrustación resultante para minimizar la distancia entre la "mejor" hipótesis y los "anclas" (fuente y referencia).

Tenga en cuenta que elegimos no incluir la fuente original

is incrustandos) en nuestra entrada concatenada. Temprano la experimentación reveló que el valor añadido por la incrustación de la fuente como características de entrada El regresor fue insignificante en el mejor de los casos. Una empínicas. ■■■ Devuelve SOLO el texto traducido, nada más.

- mastrace modelos estimados MTER entrenados con el vector
ma traduce; el siguiente texto: De... El... Se...
entrada al avance solo tiene éxito en impulsar-
Contexto: Página 3 del PDF... Texto a traducir: evaluando
nnes de idiomas descritos en la sección
ción y promediar el PEARL F... dalen base q... nter... De
tings fue +0.0009. Como se Z... le... (...), vuelve SOLO
mplemento:
mentras que los modelos preentrenados multilingües son a
Con... Página... PDF... De... Se... De... Se...

[illegible]

mensajes de chat que fueron anotados de acuerdo a la configuración para estos modelos y evaluación correspondiente establecida por Burghardt y Lommel (2024). Devuélveme la orientación traducida, nada más.

Tabla 2: Tau de Kendall (τ) correlaciones en pares de idiomas con inglés como objetivo para las Métricas WMT19 corpus. En cuanto a BLEURT, para BLEURT informamos los resultados de dos modelos: el modelo base, que es comparable en tamaño con el codificador que usamos y el modelo grande que es el doble de tamaño.

Métrica	de-en	es-en	gu-en	kk-en	Traducir el siguiente texto al español	Traducir el siguiente texto al español	Traducir el siguiente texto al español
BLEU	0.053	0.236	0.194	0.276	0.249	0.177	0.321
CHR F	0.123	0.292	0.240	0.323	0.304	0.115	0.371
Y S _Y	0.164	0.347	0.312	0.440	0.376	0.217	0.426
BERTSCORE	0.190	0.351	0.292	0.351	0.381	0.221	0.432
BERTSCORE(xlmr-base)	0.171	0.315	0.295	0.354	0.356	0.202	0.412
BLEURT	0.174	0.372	0.302	0.383	0.297	0.218	0.417
BLEURT (grande-512)	0.174	0.374	0.313	0.372	0.388	0.220	0.436
COMET	0.185	0.338	0.274	0.297	0.364	0.163	0.391
COMET MQM	0.207	0.348	0.282	0.339	0.368	0.137	0.422
COMET RANK	0.202	0.399	0.341	0.358	0.407	0.130	0.445

Tabla 3: Tau de Kendall (τ) correlaciones en el idioma pares que no involucran al inglés para las Métricas WMT19 DACorpus RR.

Métrica	de-cs	de-fr	fr-de
BLEU	0.222	0.226	0.173
CHR F	0.341	0.287	0.274
Y S _Y	0.376	0.349	0.310
BERTSCORE	0.358	0.329	0.290
BERTSCORE(xlmr-base)	0.386	0.336	0.309
COMET	0.358	0.307	0.315
COMET MQM	0.366	0.367	0.296
COMET RANK	0.389	0.414	0.331

ers. Incluso el Estimador MQM, entrenado solo con 12K segmentos, es competitivo, lo que destaca el poder de nuestro marco propuesto.

5.5 La Importancia de la Fuente

Para arrojar algo de luz sobre el valor real y la contribución de la entrada del idioma fuente en nuestros modelos, capacidad de aprender predicciones precisas, entrenamos dos versiones de nuestro modelo de clasificación RR: uno que utiliza solo la referencia, y otro que utiliza ambos referencias y experiencia y fuente. Ambos modelos fueron entrenados usando el corpus WMT 2017 que solo incluye idioma pares desde el inglés (en-de, en-cs, en-es, en-tr). En otras palabras, mientras que el inglés nunca fue observado como un idioma objetivo durante el entrenamiento para ambas variantes del modelo, el entrenamiento de la segunda variante en-es incluye incrustaciones de fuente en inglés. Luego, probamos estas dos variantes de modelo en el corpus WMT2018 para estos pares de idiomas y para la dirección inversa de traducción (con la excepción de en-cs porque no existe para WMT 2018). Los resultados en la

Tabla 4: Comparación entre COMET-RANK (asistente, 4) y RANGO-COMETA (solo de referencia, 4) en los pares de idiomas en los que se evaluó. Ambos modelos fueron entrenados con WMT17, lo que significa que el modelo solo de referencia nunca está expuesto durante el entrenamiento.

Métrica	en-es	en-de	en-es	es-es	es-es	es-es	es-es	es-es	es-es
COMET-RANK (asistente, 4)	0.666	0.704	0.666	0.595	0.549	0.595	0.459	0.428	0.428
COMET-RANK (solo de referencia, 4)	0.051	0.035	0.041	0.066	0.107	0.155	0.119	0.119	0.119
RANGO-COMETA (solo de referencia, 4)	0.051	0.035	0.041	0.024	0.107	0.155	0.119	0.132	0.132

reflejado en un nivel superior para los pares de idiomas con un espacio de incrustación y luego calcular una puntuación que refleja la similitud semántica entre esos segmentos. Sin embargo, juicios humanos como DA y MQM, capturan mucho más que solo similitud mántica, resultando en una correlación superior-mente con los juicios humanos y las puntuaciones producidas por tales métricas.

6 Reproducibilidad

Lanzaremos tanto la base de código de COMET como el marco de trabajo y los modelos de evaluación de MT entrenados descrito en este documento para la comunidad de investigación al publicarse, junto con los guiones detallados que se requiere para ejecutar todas las líneas de código. Los modelos reportados en este documento fueron entrenados en un Contexto: página 8 del PDF. Texto para traducir: una sola GPU Tesla T4 (16GB). Además, nuestro marco de trabajo se basa en PyTorch Lightning (Falcon, 2019), un envoltorio ligero de PyTorch, que fue creado para máxima flexibilidad y reproducibilidad.

7 Trabajo Relacionado

Las métricas clásicas de evaluación de MT son comúnmente caracterizadas como métricas de coincidencia de palabras, utilizando características hechas a mano, estimando la calidad de MT al contar el número y la fracción de palabras que aparecen simultáneamente en un candidato y una o más humanas-referencias. Métricas como BLEU (Papineni et al., 2002), METEOR (Banerjee y Lavie, 2005) y CHR F (Popovič, 2015) han sido ampliamente utilizadas y mejoradas (Koehn et al., 2007; Popovič, 2017; Denkowski y Lavie, 2011; Guo y Hu, 2019), pero, por diseño, generalmente no logran reconocer y capturar la similitud semántica más allá de lo léxico-nivel.

En los últimos años, las incrustaciones de palabras y otros (Mikolajczyk et al., 2013; Pennington et al., 2014; Peters et al., 2018; Devlin et al., 2019) han surgido como una alternativa comúnmente utilizada para el aprendizaje de gram para capturar la similitud semántica entre palabras. Las métricas basadas en MTEOR-V ECTOR (Banerjee y Lavie, 2005) y otros (Lo, 2019), M CONTINUOUS (Devlin et al., 2019), y BERTSCORE (Dyubel et al., 2020) crean alineaciones suaves entre referencia e hipótesis

⁶Estos se alojarán en: <https://github.com/Unbabel/COMET>

adaptado y optimizado para diferentes tipos de humanos juicios de calidad de MT.

Para demostrar la eficacia de nuestro marco, buscamos abordar los desafíos reportados en el Tarea Compartida de Métricas MAIA 2019).

Entrenamos tres modelos distintos que logran algunos resultados de vanguardia para la correlación a nivel de segmento con juicios humanos, y muestran una capacidad prometedora para diferenciar mejor los sistemas de alto rendimiento.

Uno de los desafíos de aprovechar el poder de los modelos preentrenados es el peso abrumador de los parámetros y tiempo de inferencia. Una vía principal para el trabajo futuro en COMET examinará el impacto de soluciones más compactas como DistilBERT y otros (2019).

Además, mientras esbozamos el potencial importancia del texto fuente anterior, notamos que COMET como el sistema de inteligencia artificial, referencia el texto fuente de una manera diferente durante la inferencia pero igualmente en su entrenamiento. La función de pérdida ing. El trabajo futuro investigará la optimalidad de esta formulación y examinar aún más la interdependencia de las diferentes entradas.

Reconocimientos

Estamos agradecidos a nuestros Asignados de texto, Fabio Kepler, Daan Van Stigt, Miguel Vera, y los revisores, por sus valiosos comentarios y discusiones. Este trabajo fue apoyado en parte por el Programa P2020 a través de los proyectos MAIA y Pinhaber4EU, supervisado por ANI bajo el contrato números 045909 y 042671, respectivamente.

Referencias

Mikel Artetxe y Holger Schwenk. 2019. Más-incrustaciones de frases multilingües de manera intensiva para transferencia cruzada de idiomas a COMET. *Proceedings of the Association for the Linguistic Computational*, 7:597–610.

Loïc Barrault, Ondrej Bojar, Marta R. Costa-jussà, Christian Federmann, Mark Fishel, Yvette Graham, Barry Haddow, Matthias Huck, Philipp Koehn, Shervin Malmasi, Christof Monz, Mathias Müller, Santanu Pal, Matt Post, y Marcos Zampieri. 2019. Hallazgos de la conferencia 2019 sobre traducción automática (WMT19) En *Actas de la Cuarta Conferencia sobre Traducción Automática (Volumen 2: Documentos de Trabajo)* páginas 1–61, Florencia, Italia. Asociación para la Lingüística Computacional.

Ondrej Bojar, Christian Buck, Chris Callison-Burch, Cristiano Federmann, Barry Haddow, Philipp Koehn, Christof Monz, Matt Post, Radu Soricut, y

Lucia Specia. 2013. Hallazgos del Trabajo 2013-taller sobre Traducción Automática Estadística. *Actas del Octavo Taller sobre Máquina Estadística Traducción* páginas 1–44, Sofía, Bulgaria. Asociación para la Lingüística Computacional.

Ondrej Bojar, Christian Buck, Christian Federmann, Barry Haddow, Philipp Koehn, Johannes Leveling, Christof Monz, Pavel Pecina, Matt Post, Herve Saint-Amant, Radu Soricut, Lucia Specia, y Alex Tachynina. 2014. Hallazgos del taller de 2014 sobre traducción automática estadística. *Actas de la Noveno Taller de Traducción Automática Estadística* páginas 12–58, Baltimore, Maryland, EE. UU. Asociación para la Lingüística Computacional.

Ondrej Bojar, Rajen Chatterjee, Christian Federmann, Yvette Graham, Barry Haddow, Shujian Huang, Matthias Huck, Philipp Koehn, Qun Liu, Varvara Logacheva, Christof Monz, Matteo Negri, Matt Post, Raphael Rubino, Lucia Specia, y Marco Turchi.

2017. Hallazgos de la conferencia de 2017 sobre máquina Contexto: Página 9 del PDF. *Segunda Conferencia sobre Traducción Automática* páginas 214, Copenhague, Dinamarca. Asociación para la Lingüística Computacional.

Ondrej Bojar, Rajen Chatterjee, Christian Federmann, Yvette Graham, Barry Haddow, Matthias Huck, Antonio Jimeno Yepes, Philipp Koehn, Varvara Logacheva, Christof Monz, Matteo Negri, Aurélie Néel, Manana Neves, Matt Post, Raphael Rubino, Carolina Scarton, Lucia Specia, Marco Turchi, Karin Verspoor, y Marcos Zampieri. 2016. Hallazgos de la conferencia 2016 sobre la traducción automática. *Primer Conferencia sobre Traducción Automática: Volumen 2, Documentos de Trabajo* páginas 1–48, Berlín, Alemania. Asociación para la Lingüística Computacional.

Ondrej Bojar, Rajen Chatterjee, Christian Federmann, Barry Haddow, Matthias Huck, Chris Hokamp, Philipp Koehn, Varvara Logacheva, Christof Monz, Matteo Negri, Matt Post, Carolina Scarton, Lucia Specia, y Marco Turchi. 2015. Hallazgos de la Taller de 2015 sobre traducción automática estadística. *Actas del Décimo Taller sobre Estadística Traducción Automática* páginas 1–46, Lisboa, Portugal. Asociación para la Lingüística Computacional.

Ondrej Bojar, Yvette Graham y Amir Kamran. 2017b. Resultados de las métricas compartidas de WMT17. *Actas de la Segunda Conferencia sobre Traducción Automática* páginas 489–513, Copenhague, Dinamarca. Asociación para la Lingüística Computacional.

Alexandra Berthard y Arle Lommel. 2014. *Practicas Directrices de Uso de MQM en Investigación Científica* búsqueda sobre la calidad de la traducción: 2020-05-26).

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco

- [illegible]

- marco de referencia para declarar y describir la traducción automática de texto para traducir, no puedo realizar ninguna traducción. ducci, 0:455–463.
- Qingsong Ma, Ondřej Bojar, y Yvette Graham. 2018. Resultados de la tarea compartida de métricas WMT18 para la evaluación automática de la traducción. En *Actas de la Tercera Conferencia sobre Traducción Automática: Documentos de Tarea Compartida*, páginas 671–688, Bélgica, Bruselas. Asociación para la Lingüística Computacional.
- Qingsong Ma, Johnny Wei, Ondřej Bojar, y Yvette Graham. 2019. Resultados de las métricas WMT19 para la evaluación automática de la traducción. En *Actas de la Cuarta Conferencia sobre Traducción Automática (Volumen 2: Documentos de Tarea Compartida)*, páginas 32–49, Florencia, Italia. Asociación para la Lingüística Computacional.
- Nitika Mathur, Timothy Baldwin y Trevor Cohn. 2019. Ubicando la evaluación en contexto: Contextualizando las incrustaciones mejoran la evaluación de la traducción. En *Actas de la 57ª Reunión Anual de la Asociación para la Lingüística Computacional*, páginas 2799–2808, Florencia, Italia. Asociación para la Lingüística Computacional.
- Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, y Jeff Dean. 2013. Representación distribuida de palabras. En *Advances in the Processing of Information Neural Systems*, páginas 3111–3119. Curran Associates, Inc.
- Kishore Papineni, Salim Roukos, Todd Ward, y Wei-Jing Zhu. 2002. Bleu: un método para la evaluación automática de la traducción. En *Actas de la 40ª Reunión Anual de la Asociación para la Lingüística Computacional*, páginas 311–318, Filadelfia, Pensilvania, EE. UU. Asociación para la Computación Lingüística.
- Jeffrey Pennington, Richard Socher, y Christopher Manning. 2014. GloVe: Vectores globales para la representación de palabras. En *Actas de la Conferencia 2014 sobre Métodos Empíricos en el Procesamiento del Lenguaje Natural (EMNLP)*, páginas 1532–1543, Doha, Qatar. Asociación para la Lingüística Computacional.
- Matthew Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee, y Luke Zettlemoyer. 2018. Representación de palabras profundamente contextualizada. En *Actas de la Conferencia 2018 sobre Métodos Empíricos en el Procesamiento del Lenguaje Natural (EMNLP)*, páginas 2227–2237, Nueva Orleans, Luisiana. Asociación para la Lingüística Computacional.
- Telmo Pires, Eva Schlinger, y Dan Garrette. 2019. ¿Qué tan multilingüe es el BERT multilingüe? En *Actas de la 57ª Reunión Anual de la Asociación para la Lingüística Computacional*, páginas 1996–
- 5001, Florencia, Italia. Asociación para la Computación Lingüística.
- Maja Popović. 2016. F1: puntuación f de n-gramas de caracteres para la evaluación automática de la traducción. En *Actas de la Tercera Conferencia sobre Traducción Automática Estadística*, páginas 392–395, Lisboa, Portugal. Asociación para la Lingüística Computacional.
- Maja Popović. 2017. F1++: palabras que ayudan a caracterizar n-gramas de caracteres para la traducción. En *Actas de la Segunda Conferencia sobre Traducción Automática*, páginas 2–618, Copenhague, Dinamarca. Asociación para la Computación Lingüística.
- Yusuf Reimers e Iryna Gurevych. 2019. Contexto: Página 11 del PDF. BERT: Incrustaciones de oraciones usando Siamese BERT. En *Actas de la Conferencia 2019 sobre Métodos Empíricos en el Procesamiento del Lenguaje Natural y la 9na Conferencia Internacional Conjunta sobre Naturales Procesamiento del Lenguaje (EMNLP-IJCNLP)*, páginas 3982–3992, Hong Kong, China. Asociación para la Lingüística Computacional.
- Victor Sanh, Lysandre Debut, Julien Chaumond, y Thomas Wolf. 2019. DistilBERT, una versión destilada de BERT: más pequeño, más rápido, más barato y más preciso. preprint arXiv:1910.01108.
- F. Schroff, D. Kalenichenko, y J. Philbin. 2015. FaceNet: Un aprendizaje profundo para el reconocimiento facial. En *Conferencia IEEE 2015 sobre Computación por Computadora y Reconocimiento de Patrones (CVPR)*, páginas 815–823.
- Thibault Sellam, Dipanjan Das y Ankur Parikh. 2020. BLEURT: Aprendiendo métricas robustas para texto generación. En *Actas de la 58ª Reunión Anual de la Asociación para la Lingüística Computacional*, páginas 7881–7892, En línea. Asociación para la Computación Lingüística.
- Christophe Servan, Alexandre B´erard, Zied Elloumi, Hervé Blanchon, y Laurent Besacier. 2016. Word2Vec vs DBNary: Aumentando METEOR usando representaciones vectoriales o recurrir a los diccionarios. En *Actas de COLING 2016, la 26ª Conferencia Internacional sobre Lingüística Computacional: Documentos Técnicos*, páginas 1159–1168, Osaka, Japón. El Comité Organizador de COLING 2016.
- Hiroki Shimanaka, Tomoyuki Kajiwara, y Mamoru Komachi. 2018. BERT-Regresor: utilizando oraciones incrustaciones para la evaluación automática de la traducción. En *Actas de la Tercera Conferencia sobre Traducción Automática: Documentos de Tarea Compartida*, páginas 751–758, Bélgica, Bruselas. Asociación para la Lingüística Computacional.
- Hiroki Shimanaka, Tomoyuki Kajiwara, y Mamoru Komachi. 2019. Evaluación de la Traducción Automática con BERT Regresor. preprint arXiv:1907.12670.

- Matthew Snover, Bonnie Dorr, Richard Schwartz, Linnea Micciulla, y John Makhoul. 2006. Un estudio de la tasa de edición de traducción con anotaciones humanas dirigidas a la traducción en las Américas. En las Actas de la Asociación para la Computación Lingüística, páginas 223–231.
- Lucia Specia, Frédéric Blain, Varvara Logacheva, Ramón Astudillo, y André F. T. Martins. 2018. Hallazgos de la tarea compartida WMT 2018 sobre calidad de estimación. En Actas de la Tercera Conferencia sobre Traducción Automática: Documentos y Tareas Compartidas, páginas 689–709, Bélgica, Bruselas. Asociación para Computación Lingüística.
- Lucia Specia, Kim Harris, Frédéric Blain, Aljoscha Burchardt, Vivien Macketanz, Inguna Skadina, Matteo Negri, , y Marco Turchi. 2017. Translating Quality of the translation and productivity: A study on morphological quality. En Cumbre de Traducción Automática XVI, páginas 55–71, Nagoya, Japón.
- Kosuke Takahashi, Katsuhito Sudoh, y Satoshi Nakamura. 2020. Evaluación automática de la traducción de máquinas utilizando entradas del idioma fuente y translingüístico modelo de lenguaje. En Actas de la 58ª Reunión Anual Reunión de la Asociación para la Lingüística Computacional lingüística, páginas 3553–3558, En línea. Asociación para Lingüística Computacional.
- Andre T'attar y Mark Fishel. 2017. bleu2vec: el métrica dolorosamente familiar en espacio vectorial continuo estereotipo. En Actas de la Segunda Conferencia sobre la Traducción Automática, páginas 619–622, Copenhague, Dinamarca. Asociación para Computación Lingüística.
- Ian Tenney, Dipanjan Das y Ellie Pavlick. 2019. BERT redescubre la clásica cadena de procesamiento NLP. En Actas de la 57ª Reunión Anual de la Asociación para la Lingüística Computacional, páginas 4593–4601, Florencia, Italia. Asociación para Computación Lingüística.
- Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, y Yoav Artzi. 2020. Bertscore: Evaluando la generación de texto. En Conferencia sobre Representaciones de Aprendizaje, no se proporcionó ningún texto para traducir, no puedo realizar ninguna traducción.
- Wei Zhao, Goran Glavač, Maxime Peyrard, Yang Gao, Robert West, y Steffen Eger. 2020. En el límite de los codificadores multilingües según lo expuesto por evaluación de traducción automática sin referencia. En Actas de la 58ª Reunión Anual de la Asociación para la Lingüística Computacional, páginas 1656–1671, En línea. Asociación para la Lingüística Computacional.
- Wei Zhao, Maxime Peyrard, Fei Liu, Yang Gao, Christian M. Meyer, y Steffen Eger. 2019. MoverScore: Evaluación de la generación de texto con embeddings contextualizados. En Actas de la Conferencia 2019 sobre Métodos Empíricos en Procesamiento de Lenguaje Natural y la 9ª Conferencia Conjunta Internacional sobre Procesamiento del Lenguaje Natural procesamiento (EMNLP-Joint), páginas 563–578, Hong Kong, China. Asociación para la Computación Lingüística.

A Apéndices

En la Tabla 5.1 enumeramos los hiperparámetros utilizados para entrenar nuestros modelos. Antes de inicializar estos modelos, se ejecutó un La semilla dom se estableció en 3 en todas las bibliotecas que realizan operaciones "aleatorias" (numpy ,aleatorio y cuda).

Tabla 5: Hiper-parámetros utilizados en nuestro Cde trabajo para entrenar los modelos presentados.

Hiper-parámetro	COMET (Est-HTER/MQM)	COMET (Est-ROUGE)	Como asistente, necesito el texto a traducir
Modelo de Codificador	XLM-RoBERTa (base)	XLM-RoBERTa (base)	
Optimizador	Adam (parámetros predeterminados)	Adam (parámetros predeterminados)	
en épocas congeladas	1	0	
Tasa de aprendizaje	3e-05 y 1e-05	1e-05	
Tamaño del lote	16	16	
Función de pérdida	EMC	Margen de Triplet	Como no se proporcionó
Abandono por capas	0.1	0.1	
Precisión FP	32	32	
Unidades ocultas de retroalimentación	2048, 1152		Traduce el siguiente texto al español
Activaciones Feed-Forward	Tanh		Traduce el siguiente texto al español
Abandono anticipado	0.1		Como asistente, necesito más info

Tabla 6: Estadísticas para el corpus QT21.

	en-de	en-cs	en-lv	de-en
Tuplas totales	54000	42000	35474	41998
Total de tuplas	54000	42000	35474	41998
Promedio de tokens	16.70	17.37	18.89	17.18
Promedio de tokens	16.70	17.37	18.89	17.18
Promedio de tokens	16.70	17.37	18.89	17.18

Tabla 7: Estadísticas para el WMT2017 corpus RR.


	en-cs	en-de	en-es	en-lv	Texto a traducir: en-tr
Tuplas totales	32810	6454	3270	3456	247
Total de tuplas	32810	6454	3270	3456	247
Promedio de tokens	21.37	23.41	21.73	26.08	22.51
Promedio de tokens	21.37	23.41	21.73	26.08	22.51
Promedio de tokens	21.37	23.41	21.73	26.08	22.51

00 Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.


Puntuación de Kendall Tau

00 Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.


02 Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.



	Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.
Puntuación de Kendall Tau	0 Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.



Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.



0	Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.
Puntuación de Kendall Tau	0

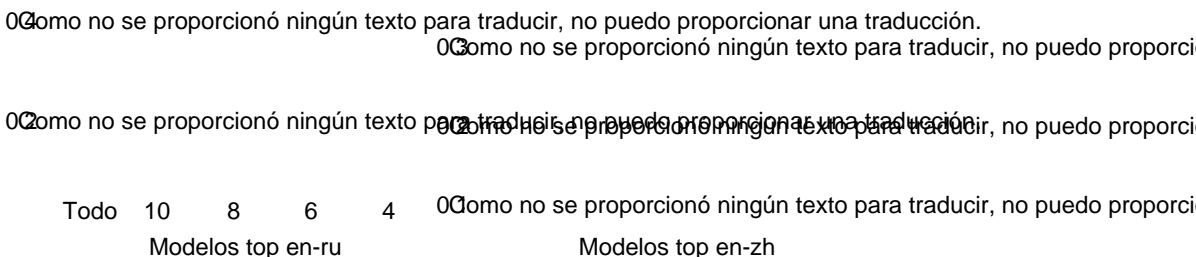


Tabla 12: Rendimiento de métricas en todos y los mejores (10, 8, 6 y 4) sistemas MT para todos los idiomas desde ing pares. El esquema de colores es el siguiente: ■ Negro sistema de O-métricas; ■ Gris sistema de BERTScore; ■ Verde sistema de BLEU; ■ Azul sistema de COMET-Monoling.

Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.

Puntuación de Kendall Tau

0 Como no se proporcionó ningún texto para traducir, no puedo realizar la traducción. Por favor, proporcione el texto

0

Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.

Regresa solo si el texto no se tradujo correctamente. Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.

Modelos top de-en

Modelos top ■-en

Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.

Puntuación de Kendall Tau

Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.

Como no se proporcionó ningún texto para traducir, no puedo realizar la traducción.

Como no se proporcionó ningún texto para traducir, no puedo proporcionar una traducción.

Como no se proporciona ningún texto para traducir, no puedo real

Como no se proporcionó ningún texto para traducir, no se puede proporcionar una traducción.

Todo 10 8 6 4
Modelos superiores It-en

0
Todo 10 8 6 4
Modelos top ru-en

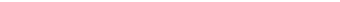




Como no se proporcionó ningún texto para traducir, no puedo realizar la traducción. Por favor, proporcione el texto

Puntuación de Kendall Tau

Como no se proporcionó ningún texto para traducir, no puedo realizar la traducción. Por favor, proporcione el texto

0

Todo 10 8 6 4
Modelos top zh-en

Tabla 13: Rendimiento de métricas en todos y los mejores (10, 8, 6 y 4) sistemas MT para todos los idiomas hacia el inglés. El esquema de colores es el siguiente:  OMT:  NMT:  OMT+NMT:  OMT+NMT+LLM:  OMT+NMT+LLM+Text2Text: 